# COE782- ML - Lista1 -Parte prática

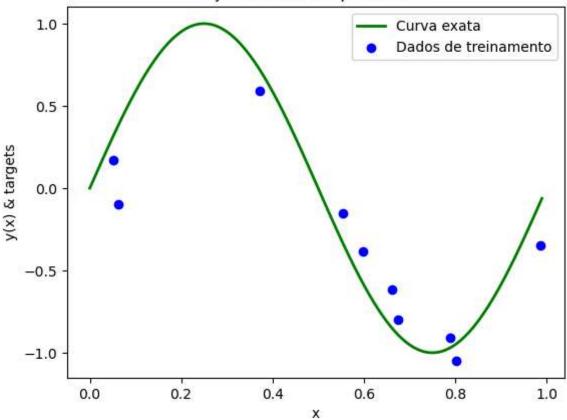
## **Experimento "Polynomial Curve Fitting"**

Aluno: Vivian de Carvalho Rodrigues

## a) Simulação das figuras 1.4 e 1.6 - Bishop

```
In [1]: #Experimento computacional "Polynomial Curve Fiting" do livro Pattern Recognitio
        #Lista 1
        import numpy as np
        import matplotlib.pyplot as plt
        from sklearn.linear_model import LinearRegression
        from sklearn.preprocessing import PolynomialFeatures
        #import math as m
        #função exata
        x = np.arange(0., 1., 0.01)
        y_f = np.sin(2*np.pi*x)
        #a) primeira parte do problema
        #gera dados com ruido
        N = 10
                                                                                       #qu
        X = np.random.rand(N, 1)
                                                                                       #da
        mu = 0.
                                                                                       #mé
        std = 0.3
                                                                                       #de
        epsilon = np.random.default_rng().normal(loc=mu, scale=std, size=(N, 1) )
                                                                                       #ru
        t = np.sin(2*np.pi*X) + epsilon
                                                                                       #ta
In [2]: # Plot do problema
        plt.plot(x, y_f, color="green", linewidth=2, label = "Curva exata")
        plt.scatter(X, t, color="blue", label = "Dados de treinamento")
        plt.xlabel("x")
        plt.ylabel("y(x) & targets")
        plt.legend()
        plt.title("Ajuste de curva polinomial")
        plt.show()
```

#### Ajuste de curva polinomial



```
In [3]: n = 3
                                                              #quantidade de modelos
        M = [1, 3, 9]
                                                              #grau do polinomio (modelos
        intercept = np.zeros(n)
        coef = np.zeros((n, max(M)))
        X_{new} = np.arange(0., 1., 1/N).reshape(N,1)
        Y = np.zeros((n,N))
        for i in range(n):
            poly_features = PolynomialFeatures(degree = M[i], include_bias=False)
            X_poly = poly_features.fit_transform(X)
            lin_reg = LinearRegression()
            lin_reg.fit(X_poly, t)
            intercept[i] = lin_reg.intercept_
            y_aux = lin_reg.predict(poly_features.fit_transform(X_new))
            for j in range(M[i]):
                coef[i][j] = lin_reg.coef_[0][j]
            for k in range(N):
                Y[i][k] = y_aux[k][0]
```

In [4]: Y

```
Out[4]: array([[ 2.52236664e-01, 1.41989066e-01, 3.17414676e-02,
                             -7.85061306e-02, -1.88753729e-01, -2.99001327e-01,
                             -4.09248925e-01, -5.19496523e-01, -6.29744121e-01,
                             -7.39991719e-01],
                           [-5.55673277e-01, 3.66110272e-01, 7.68279959e-01,
                               7.71415031e-01, 4.96094738e-01, 6.28983270e-02,
                             -4.07594954e-01, -7.94805857e-01, -9.78155133e-01,
                             -8.37063534e-01],
                           [-3.42036792e+02, -5.57075425e+01, -1.31987883e+02,
                             -4.01218158e+01, 5.45792896e+00, 1.99139724e+00,
                             -3.83857735e-01, -1.10681804e+00, -9.89466617e-01,
                             -2.15627109e+01]])
In [5]: intercept
Out[5]: array([ 2.52236664e-01, -5.55673277e-01, -3.42036792e+02])
In [6]: coef
Out[6]: array([[-1.10247598e+00, 0.00000000e+00, 0.00000000e+00,
                               0.00000000e+00, 0.0000000e+00,
                                                                                          0.00000000e+00,
                               0.00000000e+00, 0.00000000e+00,
                                                                                          0.00000000e+00],
                           [ 1.22178356e+01, -3.20096555e+01, 2.00965413e+01,
                               0.00000000e+00, 0.00000000e+00, 0.00000000e+00,
                               0.00000000e+00, 0.00000000e+00, 0.00000000e+00],
                           [ 1.59527194e+04, -2.60191069e+05, 1.88006568e+06,
                             -7.36141895e+06, 1.71612980e+07, -2.46000761e+07,
                               2.13181298e+07, -1.02613957e+07, 2.10801994e+06]])
In [7]: #Figura 1.4 Bishop
              fig, axs = plt.subplots(2, 2, figsize=(15, 15), layout='constrained')
              axs[0,0].plot(x, y_f, color="green", linewidth=2, label = "Curva exata - y(x)")
               axs[0,0].scatter(X, t, color="blue", label = "Dados de treinamento - (X,t)")
              axs[0,0].plot(X_new, np.zeros(len(X_new)), color="red", linewidth=3, label = "Rectangle of the color of the
              axs[0,0].set_xlabel("x")
              axs[0,0].set_ylabel("y(x) / targets - t/ Y(X,w)")
               axs[0,0].legend()
              axs[0,0].set_title("Ajuste de curva polinomial - grau = 0")
              axs[0,1].plot(x, y_f, color="green", linewidth=2, label = "Curva exata - y(x)")
               axs[0,1].scatter(X, t, color="blue", label = "Dados de treinamento - (X,t)")
               axs[0,1].plot(X_new, Y[0], color="red", linewidth=3, label = "Regressão - Y(X,w)
              axs[0,1].set xlabel("x")
               axs[0,1].set ylabel("y(x) / targets - t/ Y(X,w)")
               axs[0,1].legend()
              axs[0,1].set_title("Ajuste de curva polinomial - grau = "+str(M[0]))
               axs[1,0].plot(x, y f, color="green", linewidth=2, label = "Curva exata - y(x)")
               axs[1,0].scatter(X, t, color="blue", label = "Dados de treinamento - (X,t)")
               axs[1,0].plot(X_new, Y[1], color="red", linewidth=3, label = "Regressão - Y(X,w)
               axs[1,0].set_xlabel("x")
               axs[1,0].set_ylabel("y(x) / targets - t/ Y(X,w)")
               axs[1,0].legend()
              axs[1,0].set title("Ajuste de curva polinomial - grau = "+ str(M[1]))
              axs[1,1].plot(x, y_f, color="green", linewidth=2, label = "Curva exata - y(x)")
               axs[1,1].scatter(X, t, color="blue", label = "Dados de treinamento - (X,t)")
               axs[1,1].plot(X_new, Y[2], color="red", linewidth=3, label = "Regressão - Y(X,w)
```

```
axs[1,1].set_xlabel("x")
              axs[1,1].set_ylabel("y(x) / targets - t/ Y(X,w)")
              axs[1,1].legend()
              axs[1,1].set_title("Ajuste de curva polinomial - grau = "+str(M[2]))
              plt.show()
                               Ajuste de curva polinomial - grau = 0
                                                                                              Ajuste de curva polinomial - grau = 1
                                                      - Curva exata - v(x)

    Curva exata - y(x)

    Dados de treinamento - (X,t)
    Regressão - Y(X,w)

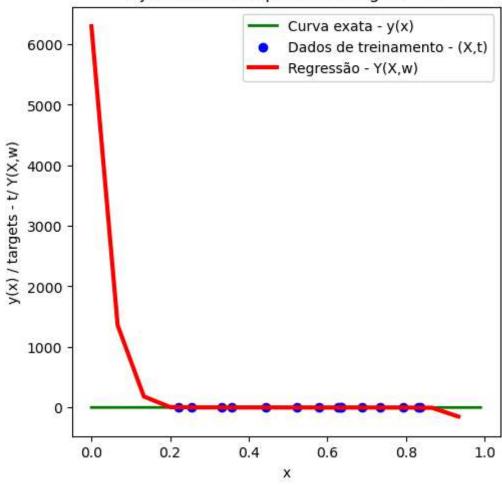
                                                                                                                   Dados de treinamento - (X,t)

Regressão - Y(X,w)
              0.5
                                                                            0.5
           y(x) / targets - t/ Y(X,w)
                                                                          y(x) / targets - t/ Y(X,w)
             -0.5
                                                                            -0.5
             -1.0
                                                                            -1.0
                  0.0
                            0.2
                                                           0.8
                                                                     1.0
                                                                                 0.0
                                                                                           0.2
                                                                                                                          0.8
                                                 0.6
                               Ajuste de curva polinomial - grau = 3
                                                                                              Ajuste de curva polinomial - grau = 9

    Curva exata - y(x)
    Dados de treinamento - (X,t)
              1.0
                                                       Regressão - Y(X,w)
                                                                            -50
              0.5
                                                                           -100
           y(x) / targets - t/ Y(X,w)
                                                                            -150
              0.0
                                                                         y(x)/
             -0.5
                                                                           -250
                                                                            -300
             -1.0
                                                                                                                      Regressão - Y(X,w)
                                                                            -350
                                                                                           0.2
                                                                                                                          0.8
 In [8]: #a) Segunda parte do problema
              M = 9
              #gera dados com ruido (15 registros)
              N = 15
                                                                                                                                    #qu
              X = np.random.rand(N, 1)
                                                                                                                                    #da
              mu = 0.
                                                                                                                                    #mé
                                                                                                                                    #de
              epsilon = np.random.default_rng().normal(loc=mu, scale=std, size=(N, 1) )
                                                                                                                                    #ru
              t = np.sin(2*np.pi*X) + epsilon
                                                                                                                                    #ta
 In [9]: #Definição da curva polinomial
              poly_features = PolynomialFeatures(degree = M, include_bias=False)
              X_poly = poly_features.fit_transform(X)
In [10]: #Regressão (aprendizado)
              lin_reg = LinearRegression()
```

```
lin_reg.fit(X_poly, t)
         lin_reg.intercept_, lin_reg.coef_
Out[10]: (array([6295.75918637]),
           array([[ -130130.10544551,
                                        1158893.27285487, -5841540.27161985,
                    18391081.89580486, -37559692.6439259, 49835872.11802647,
                   -41490873.89456611, 19698326.70720226, -4069369.8746801 ]]))
In [11]: # Gera o y (x,w) estimado com os parâmetros ajustados
         X_{\text{new}} = \text{np.arange}(0., 1., 1/N).reshape(N,1)
         Y = lin_reg.predict(poly_features.fit_transform(X_new))
In [12]: #Figura 1.6 Bishop
         fig, axs = plt.subplots(1, 1, figsize=(5, 5), layout='constrained')
         axs.plot(x, y_f, color="green", linewidth=2, label = "Curva exata - y(x)")
         axs.scatter(X, t, color="blue", label = "Dados de treinamento - (X,t)")
         axs.plot(X_new, Y, color="red", linewidth=3, label = "Regressão - Y(X,w)")
         axs.set_xlabel("x")
         axs.set_ylabel("y(x) / targets - t/ Y(X,w)")
         axs.legend()
         axs.set title("Ajuste de curva polinomial - grau = " +str(M))
         plt.show()
```

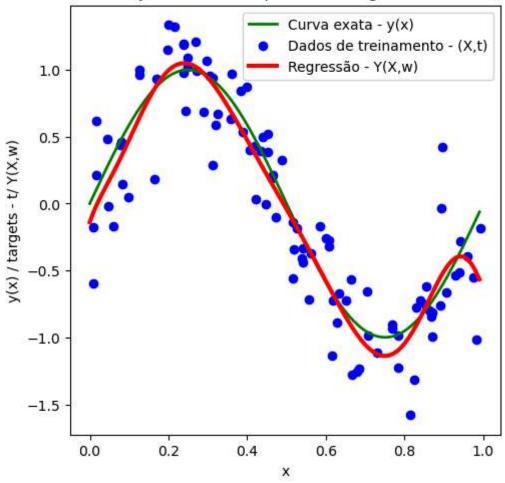
#### Ajuste de curva polinomial - grau = 9



```
In [13]: #gera dados com ruido (100 registros)
    N = 100
    X = np.random.rand(N, 1) #da
    mu = 0. #mé
    std = 0.3
```

```
epsilon = np.random.default_rng().normal(loc=mu, scale=std, size=(N, 1) )
                                                                                       #ru
         t = np.sin(2*np.pi*X) + epsilon
                                                                                       #ta
         #Definição da curva polinomial
         poly features = PolynomialFeatures(degree = M, include bias=False)
         X poly = poly features.fit transform(X)
         #Regressão (aprendizado)
         lin_reg = LinearRegression()
         lin reg.fit(X poly, t)
         lin_reg.intercept_, lin_reg.coef_
Out[13]: (array([-0.13867797]),
          array([[ 8.62184013e+00, -9.12006975e+01, 1.22925942e+03,
                   -7.70924885e+03, 2.45200737e+04, -4.37000257e+04,
                   4.43123391e+04, -2.38612508e+04, 5.29092854e+03]]))
In [14]: # Gera o y (x,w) estimado com os parâmetros ajustados
         X_{new} = np.arange(0., 1., 1/N).reshape(N,1)
         Y = lin_reg.predict(poly_features.fit_transform(X_new))
         #Figura 1.6 Bishop
         fig, axs = plt.subplots(1, 1, figsize=(5, 5), layout='constrained')
         axs.plot(x, y_f, color="green", linewidth=2, label = "Curva exata - y(x)")
         axs.scatter(X, t, color="blue", label = "Dados de treinamento - (X,t)")
         axs.plot(X_new, Y, color="red", linewidth=3, label = "Regressão - Y(X,w)")
         axs.set_xlabel("x")
         axs.set_ylabel("y(x) / targets - t/ Y(X,w)")
         axs.legend()
         axs.set_title("Ajuste de curva polinomial - grau = " +str(M))
         plt.show()
```

#### Ajuste de curva polinomial - grau = 9



## b) Dados sem relevância estatística

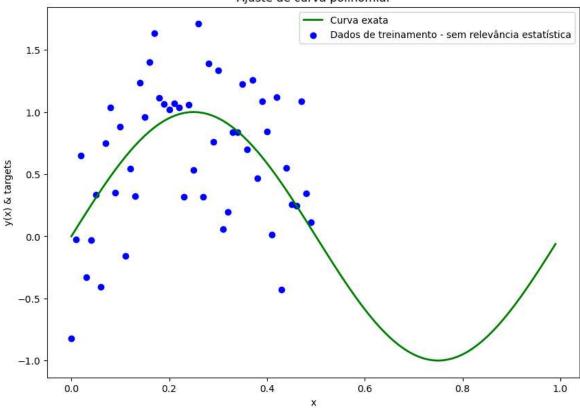
plt.ylabel("y(x) & targets")

plt.title("Ajuste de curva polinomial")

plt.legend()

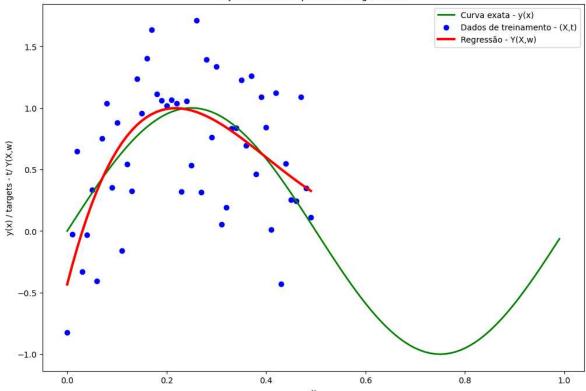
plt.show()

```
In [23]: #b) Dados sem relevância estatística
         #gera dados com ruido
         N = 50
                                                                                        #qu
         #Novos dados de entrada sem relevância estatística
         x_{aux} = np.arange(0.,0.5, 0.5/N).reshape(N,1)
         mu = 0.
                                                                                        #mé
         std = 0.5
                                                                                        #de
         epsilon = np.random.default_rng().normal(loc=mu, scale=std, size=(N, 1) )
                                                                                        #ru
         #targets alterados para perder relevância estatística
         t = np.sin(2*np.pi*x_aux) + epsilon
In [24]: # Plot do problema
         plt.figure (figsize=(10, 7))
         plt.plot(x, y f, color="green", linewidth=2, label = "Curva exata")
         plt.scatter(x_aux, t, color="blue", label = "Dados de treinamento - sem relevâno
         plt.xlabel("x")
```



```
In [25]: #Grau do polinômio
         M = 4
         #Definição da curva polinomial
          poly_features = PolynomialFeatures(degree = M, include_bias=False)
         X_poly = poly_features.fit_transform(x_aux)
         #Regressão (aprendizado)
          lin_reg = LinearRegression()
          lin_reg.fit(X_poly, t)
         lin_reg.intercept_, lin_reg.coef_
Out[25]: (array([-0.43320455]),
           array([[ 15.80985223, -55.88427279, 67.57973676, -26.36830365]]))
In [26]: # Gera o y (x,w) estimado com os parâmetros ajustados
         X_{\text{new}} = \text{np.arange}(0., 0.5, 0.5/N).reshape(N,1)
         Y = lin_reg.predict(poly_features.fit_transform(X_new))
         #Figura 1.6 Bishop
         fig, axs = plt.subplots(1, 1, figsize=(10, 7), layout='constrained')
          axs.plot(x, y_f, color="green", linewidth=2, label = "Curva exata - y(x)")
          axs.scatter(x_aux, t, color="blue", label = "Dados de treinamento - (X,t)")
          axs.plot(X_new, Y, color="red", linewidth=3, label = "Regressão - Y(X,w)")
         axs.set_xlabel("x")
          axs.set_ylabel("y(x) / targets - t/ Y(X,w)")
          axs.legend()
          axs.set title("Ajuste de curva polinomial - grau = " +str(M))
```

plt.show()

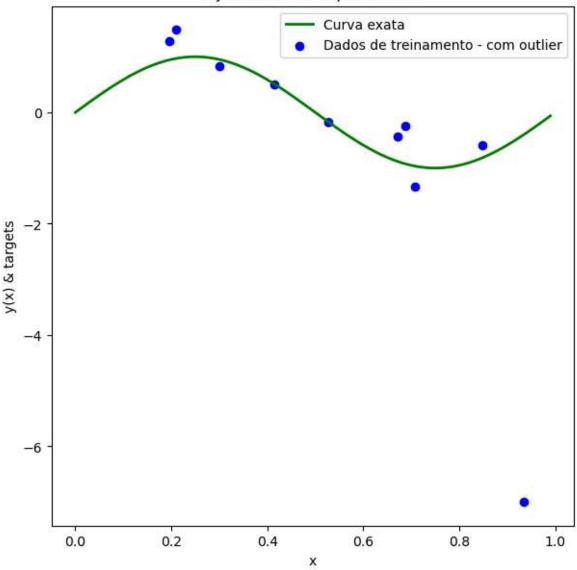


Conclusão: O modelo com dados de treinamento que não sejam relevantes para o problema, isto é, em casos de dimensão elevada, em que há atributos com baixa ou nenhuma relação mútua com o os targets, podem gerar modelos com baixíssima capacidade de generalização. O modelos final estará errado.

### c) Outlier

```
In [19]: #b) Dados sem relevância estatística
         #gera dados com ruido
         N = 10
                                                                                       #qua
         X = np.random.rand(N, 1)
                                                                                        #da
         mu = 0.
                                                                                        #mé
         std = 0.3
                                                                                        #de
         epsilon = np.random.default_rng().normal(loc=mu, scale=std, size=(N, 1) )
                                                                                        #ru
         #targets alterados para perder relevância estatística
         t = np.sin(2*np.pi*X) + epsilon
         #inclui o outlier na posição 6 do vetor do targets
         t[6] = -7
In [20]: # Plot do problema
         plt.figure (figsize=(7, 7))
         plt.plot(x, y_f, color="green", linewidth=2, label = "Curva exata")
         plt.scatter(X, t, color="blue", label = "Dados de treinamento - com outlier")
         plt.xlabel("x")
         plt.ylabel("y(x) & targets")
         plt.legend()
         plt.title("Ajuste de curva polinomial")
         plt.show()
```

#### Ajuste de curva polinomial



```
In [21]: #Grau do polinômio
M = 3
#Definição da curva polinomial
poly_features = PolynomialFeatures(degree = M, include_bias=False)
X_poly = poly_features.fit_transform(X)

#Regressão (aprendizado)
lin_reg = LinearRegression()
lin_reg.fit(X_poly, t)
lin_reg.intercept_, lin_reg.coef_
Out[21]: (array([8.50308208]), array([[-54.00278641, 112.70128238, -76.414782 ]]))
```

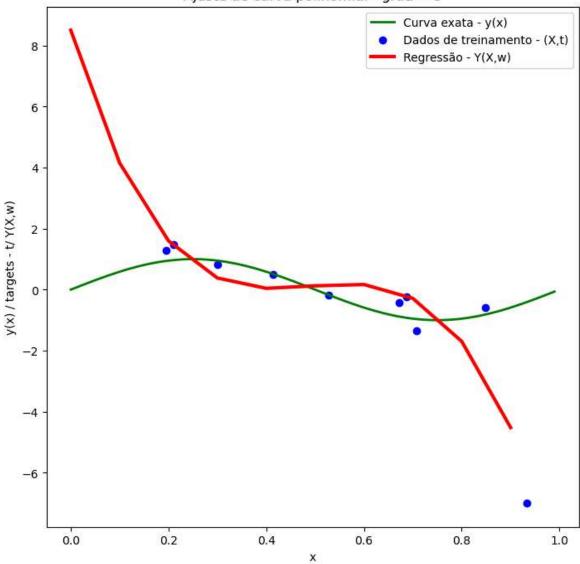
```
In [22]: # Gera o y (x,w) estimado com os parâmetros ajustados
X_new = np.arange(0., 1., 1/N).reshape(N,1)
Y = lin_reg.predict(poly_features.fit_transform(X_new))

#Figura 1.6 Bishop
fig, axs = plt.subplots(1, 1, figsize=(7, 7), layout='constrained')

axs.plot(x, y_f, color="green", linewidth=2, label = "Curva exata - y(x)")
axs.scatter(X, t, color="blue", label = "Dados de treinamento - (X,t)")
axs.plot(X_new, Y, color="red", linewidth=3, label = "Regressão - Y(X,w)")
```

```
axs.set_xlabel("x")
axs.set_ylabel("y(x) / targets - t/ Y(X,w)")
axs.legend()
axs.set_title("Ajuste de curva polinomial - grau = " +str(M))
plt.show()
```





Conclusão: Um dado errado no conjunto de treinamento, dependendo do tamanho da amostra é capaz de alterar completamente o modelo preditivo. O modelo final estará errado.

In [ ]: